




Centrale Lille

SOUTENANCE PROJET APR

Chouillou Thao / Thube Hugo

PLAN

- 1 Présentation du jeu de données
- 2 Objectif à réaliser pour notre réseau de neurone + méthode
- 3 1er réseau sur les données simplifiée
- 4 2ème réseau données complètes
- 5 Clustering
- 6 Conclusion

1. PRÉSENTATION DES DONNÉES


Rk	Player	Nation	Pos	Squad	Comp	Age	Born	Playing Time				Performance										Expected				Progression			
								MP	Starts	Min	90s	GS	Asst	G+A	G-PK	PK	PKatt	CrdY	CrdR	xG	npG	xAG	npG+xAG	PrdC	PrdP	PrdR	GS	Asst	G+A
1	Max Aarons	ENG	DF	Bournemouth	Premier League	24	2000	2	1	86	1.0	0	0	0	0	0	0	0	0	0.0	0.0	0.0	0.0	1	8	3	0.00	0.00	0.00
2	Max Aarons	ENG	DF,MF	Valencia	La Liga	24	2000	4	1	120	1.3	0	0	0	0	0	0	2	0	0.0	0.0	0.0	0.0	0	6	10	0.00	0.00	0.00
3	Rodrigo Abalo	ESP	DF	Valencia	La Liga	21	2003	1	1	65	0.7	0	0	0	0	0	0	1	0	0.1	0.1	0.0	0.1	3	2	3	0.00	0.00	0.00
4	Janos Abankwah	ITA	DF,MF	Inter	Serie A	20	2004	6	0	88	1.0	0	0	0	0	0	0	1	0	0.1	0.1	0.0	0.1	3	4	1	0.00	0.00	0.00
5	Kevane Adnan	FRA	FW	Marseille	Ligue 1	18	2006	1	0	3	0.0	0	0	0	0	0	0	0	0	0.0	0.0	0.0	0.0	1	0	0	0.00	0.00	0.00
6	Yous Abdelhamid	MAR	DF	Saint-Etienne	Ligue 1	36	1987	16	11	1,033	11.5	0	0	0	0	0	0	2	0	0.2	0.2	0.1	0.4	4	22	3	0.00	0.00	0.00
7	Hamed Abdoli	ALG	MF,FW	Angers	Ligue 1	24	1999	32	32	2,842	31.6	6	1	7	3	3	4	4	0	6.4	3.2	3.2	6.4	107	207	111	0.19	0.03	0.22
8	Mohamed Abdelmonem	EGY	DF	Nice	Ligue 1	25	1999	12	10	855	9.5	0	0	0	0	0	0	2	0	0.0	0.0	0.0	0.0	5	52	5	0.00	0.00	0.00
9	Ali Abdi	TUN	DF,MF	Nice	Ligue 1	30	1993	25	17	1,393	15.5	5	2	7	5	0	0	2	0	4.3	4.3	1.9	6.2	35	42	101	0.32	0.13	0.45
10	Saud Abdulhamet	NSA	DF	Roma	Serie A	25	1999	4	2	205	2.3	0	1	1	0	0	0	0	0	0.0	0.0	0.2	0.2	6	9	26	0.00	0.44	0.44
11	Abel	ESP	DF	Osasuna	La Liga	23	2000	35	20	2,074	23.0	2	0	2	2	0	0	3	0	0.5	0.5	1.0	1.6	50	77	92	0.09	0.00	0.09
12	Nabil Aboelenen	FRA	MF	Metz	La Liga	21	2002	7	4	263	2.9	0	0	0	0	0	0	1	0	0.0	0.0	0.0	0.1	2	6	2	0.00	0.00	0.00
13	Oliver Aboelenen	DEN	MF	Congo	Serie A	28	1996	1	0	7	0.1	0	0	0	0	0	0	0	0	0.0	0.0	0.0	0.0	0	0	0	0.00	0.00	0.00
14	Matthias Abou	FRA	FW	Nantes	Ligue 1	21	2003	34	33	2,768	30.8	9	2	11	8	1	1	3	0	8.5	7.7	3.8	11.5	75	48	169	0.29	0.07	0.36
15	Abner	BRA	DF	Lyon	Ligue 1	24	2000	19	12	1,090	12.1	1	1	2	1	0	0	1	0	0.6	0.6	1.1	1.7	31	66	55	0.08	0.08	0.17
16	Zakaria Aboukhail	MAR	MF,FW	Bath	Ligue 1	24	2000	26	22	1,901	21.1	7	2	9	6	1	2	4	0	10.2	8.6	1.6	10.2	34	22	164	0.33	0.05	0.43
17	Abdel Abo	MAR	DF	Alexis	La Liga	25	1999	29	29	2,463	27.4	0	1	1	0	0	0	13	0	0.9	0.9	0.3	1.2	16	79	4	0.00	0.04	0.04
18	Timmy Abraham	ENG	FW	Roma	Serie A	26	1997	1	0	1	0.0	0	0	0	0	0	0	0	0	0.0	0.0	0.0	0.0	0	1	2	0.00	0.00	0.00
19	Timmy Abraham	ENG	FW	Milan	Serie A	26	1997	28	12	1,183	13.1	3	4	7	2	1	2	1	0	7.1	5.4	2.2	7.6	8	26	69	0.23	0.30	0.53
20	Federico Accornero	ITA	MF	Genoa	Serie A	20	2004	1	0	5	0.1	0	0	0	0	0	0	0	0	0.0	0.0	0.0	0.0	0	0	0	0.00	0.00	0.00
21	Francesco Acerbi	ITA	DF	Inter	Serie A	36	1988	23	20	1,710	19.0	0	1	1	0	0	0	0	0	0.4	0.4	0.6	1.0	19	62	22	0.00	0.05	0.05
22	Joshua Achampong	ENG	DF	Chelsea	Premier League	18	2006	4	2	170	1.9	0	0	0	0	0	0	1	0	0.2	0.2	0.0	0.2	0	8	0	0.00	0.00	0.00
23	Akai Adams	NGA	FW	Sevilla	La Liga	24	2000	4	1	134	1.5	0	0	0	0	0	0	0	0	0.4	0.4	0.0	0.4	0	5	5	0.00	0.00	0.00
24	Akai Adams	NGA	FW	Montpellier	Ligue 1	24	2000	15	13	1,075	11.9	3	1	4	3	0	0	2	0	4.3	4.3	1.0	5.3	11	6	45	0.25	0.08	0.33
25	Che Adams	SCO	FW	Spino	Serie A	28	1996	26	30	2,652	29.5	9	3	12	9	0	1	2	0	9.0	8.2	2.0	10.2	23	40	153	0.31	0.10	0.41




1. PRÉSENTATION DES DONNÉES

- On regroupe toutes les données dans différents fichiers .csv
- Grâce à un programme python on les traite et on crée deux fichiers globaux :

Postes simplifiés




Postes de bases



2.OBJECTIF POUR NOTRE RÉSEAU DE NEURONNE + MÉTHODE

- Réussir à prédire le **poste** d'un joueur de foot
- Travail sur le jeu de données avec **4 classes** seulement pour parvenir à créer un **réseau** intéressant → on adaptera ce réseau pour le cas à **10 classes**
- Méthode : réseau simple que l'on complexifie petit à petit
- Dernière couche comporte autant de neurones que de classes





3. CONSTRUCTION DU RÉSEAU POUR 4 CLASSES

ÉTAPE 1: RÉSEAU 1 COUCHE

On propose un réseau 1 couche avec autant de neurones que de classe (4 neurones) :

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 4)	628



- Acuracy très moyenne
- Perte ne se stabilise pas

=> réseau n'arrive pas à apprendre (trop simple)



3. CONSTRUCTION DU RÉSEAU POUR 4 CLASSES

ÉTAPE 2: RÉSEAU 2 COUCHES

On propose un réseau avec 2 couches et toujours 4 neurones

Layer (type)	Output Shape	Param #
dense_1 (Dense)	(None, 4)	628
dense_2 (Dense)	(None, 4)	20

40/40 — 0s 847us/step — accuracy: 0.3207 — loss: 1.3065
Test accuracy: 0.34
Test accuracy: 0.34



- Acuracy moyenne
- La perte se stabilise mieux

=> réseau apprend mais toujours trop simple



3. CONSTRUCTION DU RÉSEAU POUR 4 CLASSES

ÉTAPE 3: RÉSEAU 3 COUCHES ET PLUS DE NEURONES

On propose un réseau avec 3 couches et on augmente le nombre de neurones (64 → 32 → 4) + fonction d'activation = "relu"

Layer (type)	Output Shape	Param #
dense_3 (Dense)	(None, 64)	10,048
dense_4 (Dense)	(None, 32)	2,080
dense_5 (Dense)	(None, 4)	132

40/40 — 0s 865us/step — accuracy: 0.3219 — loss: 1.3034
Test accuracy: 0.35
Test accuracy: 0.35



- Acuracy ne progresse pas
- La perte se stabilise mieux


=> réseau apprend mais toujours trop simple

3. CONSTRUCTION DU RÉSEAU POUR 4 CLASSES

ÉTAPE 4: NORMALISATION

On propose un réseau avec 3 couches et on augmente le nombre de neurones ($128 \rightarrow 64 \rightarrow 4$) + NORMALISATION des données (équilibrer le poids des données)

Layer (type)	Output Shape	Param #
dense_30 (Dense)	(None, 128)	20,096
dense_31 (Dense)	(None, 64)	8,256
dense_32 (Dense)	(None, 4)	260



- Réseau s'entraîne mieux
- Très performant sur les données d'entraîneemnt
- Perte remonte sur les données de validation

=> on est dans un cas de **SURAPENTISSAGE !**



3. CONSTRUCTION DU RÉSEAU POUR 4 CLASSES

ÉTAPE 5: RÉDUCTION DU NOMBRE DE NEURONES

On propose un réseau avec 3 couches et on réduit le nombre de neurones ($16 \rightarrow 8 \rightarrow 4$) + NORMALISATION des données (équilibrer le poids des données)

Layer (type)	Output Shape	Param #
dense_10 (Dense)	(None, 16)	2,512
dense_11 (Dense)	(None, 8)	136
dense_12 (Dense)	(None, 4)	36

Test accuracy: 0.85
Test accuracy: 0.85



- Réseau s'entraîne bien
- On est presque sorti du surapprentissage

=> on a un réseau qui détecte bien le poste d'un joueur



3. CONSTRUCTION DU RÉSEAU POUR 4 CLASSES

ÉTAPE 6: RAJOUTE UN DROPOUT

On rajoute des dropouts pour combler le petit surapprentissage :

Layer (type)	Output Shape	Param #
dense_12 (Dense)	(None, 16)	2,512
dropout (Dropout)	(None, 16)	0
dense_13 (Dense)	(None, 8)	136
dropout_1 (Dropout)	(None, 8)	0
dense_14 (Dense)	(None, 4)	36


Test accuracy: 0.86
Test accuracy: 0.86



- On a encore moins de surapprentissage
- Amélioration très légère

=> on a un réseau qui détecte bien le poste d'un joueur : 86% > 25%

RESULTAT DES PREDICTIONS



Bonne partie des prédictions qui est bonne pour chaque poste + pas de grosse fautes :

==> VALIDATION DU MODELE



4. CONSTRUCTION DU RÉSEAU POUR 10 CLASSES

ÉTAPE 1: REPRENONS LE RÉSEAU PRÉCÉDENT

On reprend le réseau précédent : adapte la couche de sortie (10 postes à prédire)

Layer (type)	Output Shape	Param #
dense_16 (Dense)	(None, 16)	2,512
dense_17 (Dense)	(None, 8)	136
dense_18 (Dense)	(None, 10)	90

40/40 — 0s 815us/step — accuracy: 0.6758 — loss: 0.9064
Test accuracy: 0.69
Test accuracy: 0.69



- Accuracy moins bonne que pour 4 classes
- perte correcte pas de surapprentissage

Le réseau fonctionne mais manque un peu de précision



4. CONSTRUCTION DU RÉSEAU POUR 10 CLASSES

ÉTAPE 2: AUGMENTE LE NOMBRE DE NEURONES

On ajoute des neurones en plus dans les couches + dropout pour éviter le surapprentissage

Layer (type)	Output Shape	Param #
dense_15 (Dense)	(None, 64)	10,048
dropout_2 (Dropout)	(None, 64)	0
dense_16 (Dense)	(None, 32)	2,080
dropout_3 (Dropout)	(None, 32)	0
dense_17 (Dense)	(None, 10)	330


40/40 — 0s 815us/step — accuracy: 0.6826 — loss: 0.8725
Test accuracy: 0.70
Test accuracy: 0.70



- Pas d'amélioration notable

L'apprentissage stagne à 70% : pourquoi ? ...

RESULTAT DES PREDICTIONS



Bonne prédictions des postes unique : beaucoup de mal sur les postes doubles

ON VA RÉALISER UN CLUSTERING POUR ESSAYER DE COMPRENDRE CE QU'IL SE PASSE

1

Objectif : déterminer les profils de joueurs similaires en fonction de leur statistiques

2

Création d'un autoencodeur que l'on va entraîner

3

Clustering par la méthode des k-moyens

4


Interprétation des résultats

AUTOENCODEUR ?

Utilisation d'un autoencodeur pour réduire la dimension des données dans un espace 2D (éviter le phénomène de la malédiction de la dimensionnalité)


- Encodeur pour réduire la dimension
- Décodeur : permet d'accéder à l'erreur de reconstruction pour entrainer le réseau (MSE)
- On obtient ainsi des embeddings corrects de nos données pour appliquer la méthode des k-moyens

Layer (type)	Output Shape	Param #
input_layer_23 (InputLayer)	(None, 156)	0
dense_70 (Dense)	(None, 64)	10,048
dense_71 (Dense)	(None, 32)	2,080
latent (Dense)	(None, 2)	66
dense_72 (Dense)	(None, 32)	96
dense_73 (Dense)	(None, 64)	2,112
dense_74 (Dense)	(None, 156)	10,140




CLUSTER: MÉTHODE DES K-MOYENS

- Regrouper les points qui se ressemblent dans des même clusters
- Création de k clusters
- Permet de regrouper les points de notre embedding



Embeddings 2D - Couleur par Cluster K-Means



On répatie en 10 clusters pour voir si cela va correspondre ou non avec les 10 postes

INTERPRÉTATION

Répartition des postes réels par cluster K-Means



- On retrouve bien une relation entre poste et certains clusters (3/5/6/7)
- Cependant ce n'est pas du tout trié dans les autres clusters

=> Les clusters ne définissent pas complètement les poles

Le profil des joueurs créer à partir de leur statistiques ne permet pas de retrouver leur poste. Cela explique en partie l'erreur plus importante que l'on a sur le modèle pour 10 classes

CONCLUSION

- Très bon réseau (86%) pour prédire les 4 grands postes
- Réseau correct (70%) pour prédire les 10 postes
- Le clustering met en avant le fait que les statistiques des joueurs permettent d'établir des relations entre les joueurs (des profils similaires) qui ne collent pas forcément à leur poste d'où les erreurs pour prédire les 10 postes

The background features a series of light blue wavy lines that flow across the middle of the slide. In the top-left corner, there is a grid of small blue dots. In the top-right corner, there is a solid blue rectangle. In the bottom-right corner, there is another grid of small blue dots. The word "MERCI" is centered in the middle of the slide in a bold, blue, sans-serif font.

MERCI